



Instituto Tecnológico
de Buenos Aires

Diplomatura en Ciencia de Datos

Módulo 2: Machine Learning

TP Nro 1°

Profesor: Marcela Leticia Riccillo

Nombre: Ivan Kim

DNI: 37.687.040

EJERCICIO 1 - TEORÍA

¿Por qué es importante testear un modelo de Machine Learning?

Como se ha dicho en clase siempre hay que testear un modelo de machine learning primero para comprobar que funcionen y luego poder compararlo con otros modelos para elegir cuál se ajusta mejor a los datos.

Por otro lado, para evitar overfitting o que aprende de memoria sino que generalice y pueda predecir y generar resultados en base a lo aprendido.

Esto hace que el modelo tenga confiabilidad para la toma de decisiones de casos reales por ejemplo en salud, donde es importante la precisión de los resultados y reducir riesgos potenciales.

EJERCICIO 2 - REGRESIÓN

1) Indique el nombre del dataset, y la librería de R o la página web fuente del mismo.

El dataset que vamos a usar es de la librería R “**EuStockMarkerts**”

2) Identifique la variable a predecir (indique el nombre textual de la variable) y de qué trata el caso a predecir.

La variable a predecir sería SMI (Swiss Market Index) donde su objetivo muestra el valor del índice de bolsa de Suiza en relación con los otros índices dentro de la base que son Alemania (DAX), Francia (CAC) e Inglaterra (FTSE).

3) Muestre un dim y un summary de la base.

Aca se muestra el summary de la base de datos.

La mínima, la máxima, los rangos intercuartiles, la media y la mediana.

summary(EuStockMarkets)

Summary by variable			
DAX	SMI	CAC	FTSE
Min. :1402	Min. :1587	Min. :1611	Min. :2281
1st Qu.:1744	1st Qu.:2166	1st Qu.:1875	1st Qu.:2843
Median :2141	Median :2796	Median :1992	Median :3247
Mean :2531	Mean :3376	Mean :2228	Mean :3566
3rd Qu.:2722	3rd Qu.:3812	3rd Qu.:2274	3rd Qu.:3994
Max. :6186	Max. :8412	Max. :4388	Max. :6179

El **dim(EuStockMarkets)** muestra la cantidad de registros y columnas de la base.

[1] 1860 4

4) ¿Cuántos registros tiene la base? ¿Cuántas variables? ¿De qué tipo son las variables?


4 variables y 1860 registros.

Variable del tipo numérico continuo.

5) Realice un histograma de la variable a predecir. ¿En qué rango se encuentran los valores?

`hist(base$variable,main="Título",col="color")`

El rango de los valores es entre 2000 a 8000 (valor de mercado)
y la frecuencia es de 0 a 400 (días donde ese valor se mantuvo dentro de ese rango)



a) Para el título ingrese su nombre, como “Histograma de Marcela”.

El título utilizado fue “Histograma de Iván”

b) Elija un color para el gráfico. Tenga en cuenta que ingresa colors() en R verá que hay +500 colores posibles.

El color usado para el histograma fue “Magenta”

c) Indique el código R utilizado.

```
data(EuStockMarkets)
```

```

EuStMkt_df <- as.data.frame(EuStockMarkets)

view(EuStMkt_df)

str(EuStockMarkets)

dim(EuStockMarkets)

summary(EuStockMarkets)

hist(EuStMkt_df$SMI, main = "Histograma de Ivan", col = "magenta")

```

Parte B - Conjuntos

- 1) Considere su DNI para el seteo de la semilla y particione la base en un conjunto de entrenamiento y uno de testeo con la librería caret.

Además, si su DNI termina en 0, 1, 2 ó 3

Setee p=0.70

Si su DNI termina en 4, 5, 6 ó 7

Setee p=0.75

Si su DNI termina en 8 ó 9

Setee p=0.80

```

set.seed(DNI);particion=createDataPartition(y=BASE$VariableAPred,p=asignad
o,list=FALSE)
entreno=BASE[particion,]
testeo=BASE[-particion,]

```

Indique cómo quedó el código R utilizado.

```

library(caret)
set.seed(37687040)
particion <- createDataPartition(y = EuStMkt_df$SMI, p = 0.70, list = FALSE)
entreno <- EuStMkt_df[particion, ]
testeo <- EuStMkt_df[-particion, ]

dim(entreno) - dio 1304 registros
dim(testeo) - dio 556 registros

```

```

> dim(entreno)
[1] 1304    4
> dim(testeo)
[1] 556    4

```

2) Muestre un head y un summary del conjunto de entrenamiento y del conjunto de testeo.

head(entreno) - muestra los valores de la base de entreno.

```
DAX      SMI      CAC      FTSE
1 1628.75 1678.1 1772.8 2443.6
4 1621.04 1684.1 1708.1 2470.4
5 1618.16 1686.6 1723.1 2484.7
6 1610.61 1671.6 1714.3 2466.8
7 1630.75 1682.9 1734.5 2487.9
8 1640.17 1703.6 1757.4 2508.4
```

summary(entreno) - La mínima, la máxima, los rangos intercuartiles, la media y la mediana de la base entreno.

```
DAX              SMI              CAC              FTSE
Min.   :1402    Min.   :1596    Min.   :1611    Min.   :2285
1st Qu.:1742   1st Qu.:2166   1st Qu.:1876   1st Qu.:2839
Median  :2143   Median  :2796   Median  :1995   Median  :3234
Mean    :2536   Mean    :3384   Mean    :2230   Mean    :3569
3rd Qu.:2722   3rd Qu.:3812   3rd Qu.:2275   3rd Qu.:3992
Max.    :6186   Max.    :8401   Max.    :4388   Max.    :6179
```

head(testeo) muestra los valores de la base de testeo.

```
DAX      SMI      CAC      FTSE
2 1613.63 1688.5 1750.5 2460.2
3 1606.51 1678.6 1718.0 2448.2
9 1635.47 1697.5 1754.0 2510.5
11 1647.84 1723.8 1759.8 2532.5
14 1621.49 1733.3 1757.5 2547.3
16 1627.63 1728.3 1762.8 2558.5
```

summary(testeo) - La mínima, la máxima, los rangos intercuartiles, la media y la mediana de la base testeo.

DAX	SMI	CAC	FTSE
Min. :1454	Min. :1587	Min. :1646	Min. :2281
1st Qu.:1745	1st Qu.:2178	1st Qu.:1873	1st Qu.:2847
Median :2134	Median :2798	Median :1985	Median :3265
Mean :2517	Mean :3358	Mean :2222	Mean :3559
3rd Qu.:2711	3rd Qu.:3806	3rd Qu.:2259	3rd Qu.:3994
Max. :6184	Max. :8412	Max. :4340	Max. :6133

3) ¿Cuántos registros quedaron en cada conjunto (entrenamiento y testeo) en total?

Seteando el p.valor a 0.70

Se usa la base en 70% de entrenamiento y 30% de testeo.

nrow(entreno) → 1304 Registros

nrow(testeo) → 556 Registros

```
> nrow(testeo)
[1] 556
> nrow(entreno)
[1] 1304
>
```

ANEXO CODIGO R

PARTE A

```
data(EuStockMarkets)
EuStMkt_df <- as.data.frame(EuStockMarkets)

view(EuStMkt_df)

str(EuStockMarkets)

dim(EuStockMarkets)

summary(EuStockMarkets)

hist(EuStMkt_df$SMI, main = "Histograma de Ivan", col = "magenta")
```

PARTE B

```
library(caret)
set.seed(37687040)
particion <- createDataPartition(y = EuStMkt_df$SMI, p = 0.70, list = FALSE)
entreno <- EuStMkt_df[particion, ]
testeo <- EuStMkt_df[-particion, ]

dim(entreno)
dim(testeo)

head(entreno)
summary(entreno)
head(testeo)
summary(testeo)

nrow(testeo)
nrow(entreno)
```